

Programming Homework (คะแนนเดี่ยว 10% + คะแนนกลุ่ม 30%)

1. การบ้านนี้เป็นงานกลุ่ม กำหนดให้ 1 กลุ่มมีสมาชิก 3-4 คน
2. การให้คะแนนแบ่งเป็นดังต่อไปนี้
 - 1) **คะแนนกลุ่ม 30%**
 - 20% คือ คะแนนที่อาจารย์ประเมินจากคุณภาพของชิ้นงาน และการนำเสนอผลงาน
 - 10% คือ คะแนนที่อาจารย์ประเมินจากคุณภาพการตอบคำถามและตอบคอมเมนต์ ที่ทางกลุ่มได้รับจากเพื่อน ๆ ในคลาส
 - 2) **คะแนนเดี่ยว 10%** คือ คะแนนที่นักศึกษาแต่ละคนไปคอมเมนต์ (เชิงเทคนิคัล) ให้กับงานของเพื่อนอีก 5 กลุ่ม แล้ว screen capture คอมเมนต์ของตัวเองรวมใส่ไฟล์ PDF ส่งให้อาจารย์ใน assignment
3. การบ้านครั้งนี้ไม่จำเป็นต้องส่งเป็น Github และไม่จำเป็นต้องส่งรายงานใด ๆ แนะนำเสนอผลการทดลองที่ได้ผ่านไฟล์การนำเสนอ ทั้งนี้หากกลุ่มไหนต้องการทำงานเก็บไว้ใน Github เพื่อเป็น profile/portfolio อาจารย์มีตัวอย่างของรุ่นพี่ให้ดูดังนี้ค่ะ (ลิงก์ที่ 2 กับ 3 จะหัวข้อใกล้เคียงกับ Programming Homework ครั้งนี้)
 - https://github.com/lukplamino/DADS7202_HW01_MNLP_Group
 - https://github.com/lukplamino/DADS7202_HW02-CNN_MNLP_Group
 - <https://github.com/dads7202/assignment2>
4. หัวข้อการบ้านคือให้แต่ละกลุ่มเตรียสร้าง Image Classifier ด้วย CNN บน A new image dataset ที่พวกเรารวบรวมมาเอง โดยมีเงื่อนไขดังนี้ค่ะ
 - 1) คลาสที่จะเลือกมาให้โมเดลพยากรณ์ต้องเป็นคลาสที่อยู่นอกเหนือจาก 1,000 ImageNet classes หรือก็คือ หากเอาภาพคลาสเหล่านี้ไปให้ CNN (pre-trained on ImageNet) พยากรณ์เลยโดยไม่เทรนใด ๆ เพิ่มเติม ผลลัพธ์การพยากรณ์จะไม่ถูกต้อง (เช่น จำแนกผิดไปเป็นคนละคลาสเลย) หรือถูกต้องแค่บางส่วน (เช่น จำแนกได้ว่าเป็นรถ แต่จำแนกละเอียดลงไปว่าเป็นรถตึก ๆ ไม่ได้)
 - ตัวอย่างยอดฮิตของรุ่นพี่ เช่น คลาสรถสไลด์ไทย ๆ (ตึกๆ กระบะ อีแต่น ฯลฯ) คลาสขนมไทย คลาสผลไม้ไทย ฯลฯ
 - 2) นักศึกษาในกลุ่มต้องเป็นผู้รวบรวม A new image dataset ของกลุ่มขึ้นมาเอง โดยอาจเป็นการรวมภาพจาก public dataset หลาย ๆ อันมาประกอบเข้าด้วยกัน, การทำ web scraping ภาพมา

เพิ่มเติม, การถ่ายรูปมาเองบางส่วน, หรือใช้เทคนิคข้างต้นผสมผสานกันเพื่อให้ได้เซตภาพเป้าหมายตามที่ต้องการ แต่จะต้องไม่ใช่การนำ Image dataset ที่มีอยู่แล้วมาใช้ตรง ๆ โดยนักศึกษาไม่ได้มีการรวบรวมข้อมูลเพิ่มเติมเองเพื่อสร้าง A new dataset นี้เลย

- 3) เพื่อให้ dataset ที่ได้มีความหลากหลาย A new image dataset ของแต่ละกลุ่มจะต้องหัวข้อไม่ซ้ำกันนะคะ กลุ่มไหนจะก่อนได้ก่อน พิมพ์จงบอกรายละเอียด reply ได้โพสต์ส่งหัวข้อการบ้าน บอกชื่อกลุ่ม ชื่อ class ที่จะทำ และใส่ @ tag ชื่อสมาชิกในกลุ่มทุกคนด้วยค่ะ
- 4) ในส่วนของตัวโมเดล Foundation (Pre-trained) CNN ที่จะเลือกมาใช้เป็น backbone (feature extractor) จะต้องเลือกอย่างน้อย 3-5 architectures ที่แตกต่างกันอย่างมีนัยสำคัญ เพื่อทดลองเปรียบเทียบกันว่า architecture ใดจะให้ผลลัพธ์ที่ดีที่สุดในการวิเคราะห์แต่ละด้าน
 - เช่น ถ้าเลือก VGG-16 กับ VGG-19 จะถูกนับว่าเป็นแค่การทดลองบน 1 architecture แต่ถ้าเลือก VGG-16, ResNet-50, EfficientNet-B7 อย่างนี้จึงจะนับเป็นการทดลองบน 3 architectures ค่ะ
- 5) ในส่วนของการเทรนโมเดลนั้น ไม่จำกัดว่าจะใช้ transfer learning (ไม่ต้อง ImageNet weights ของเดิมเลย) หรือ finetuning (มีการอัปเดต ImageNet weights ในบางเลเยอร์ของโมเดล) นักศึกษาแต่ละกลุ่มสามารถทดลองได้เอง เพื่อให้ได้ผลลัพธ์ที่ดีที่สุด
5. การเตรียมข้อมูลนำเสนอให้เตรียมเรียงตามหัวข้อนี้เลยคะ เป็น standard ของการรายงานผลการทดลองด้าน Deep Learning (1 กลุ่มมีเวลานำเสนอในคลาสแค่ประมาณ 5 นาทีนะคะ เน้นพูดเฉพาะประเด็นสำคัญและใส่รายละเอียดที่เหลือไว้ในไฟล์นำเสนอคะ)
 - 1) Dataset description
 - ที่มาของข้อมูลว่านำมาจากแหล่งไหนบ้าง ถ้าถ่ายรูปมาเองให้บอก setting ต่าง ๆ ของการถ่ายรูปด้วย (เพื่อแสดงว่ากระบวนการเก็บภาพไม่มี bias)
 - Exploratory Data Analysis (EDA) ของ dataset เบื้องต้น เช่น จำนวนภาพแต่ละคลาสมีเท่าไร, ภาพแต่ละภาพขนาดเท่าไร, ภาพสีกี่ภาพ ภาพ grayscale กี่ภาพ, ความแตกต่างของ brightness ในภาพ ฯลฯ
 - Dataset ที่นำมาใช้มีความ imbalanced ในจำนวนภาพระหว่างคลาสหรือไม่? ถ้ามีต้องนำเสนอว่าจะแก้ปัญหา imbalanced dataset นี้ยังไง ***อันนี้สำคัญนะคะ ขอให้แจ้งตรงนี้ให้ชัดเจนทุกกลุ่ม***

2) Data preparation

- ลำดับขั้นตอนที่ชัดเจนในการ preprocess และ/หรือ postprocess ข้อมูลรูปภาพของเราค่ะ เช่น การย่อขนาดภาพ, การ crop ภาพ, การ shuffle dataset, การ split, การ augmentation ฯลฯ
- วิธีการทำ train / validation / test split ว่ามีหลักคิดและหลักการแบ่งยังไง (เช่นใช้ random splitting หรือใช้ stratified data splitting หรือใช้ manual splitting) เมื่อแบ่งแล้วได้เซตละเท่าไร จำนวนในแต่ละคลาสสมดุลกันไหม
- การทำ data augmentation บนรูปภาพที่จะใช้เป็น training sample ของเราเลือกใช้ operation ใดบ้าง (เลือกตามความเหมาะสมของ dataset นะคะ) ***อันนี้ขอว่าทุกกลุ่มต้องทำ data augmentation นะคะ แต่จะใช้วิธีการ offline หรือ online ก็ได้ค่ะ***

3) Model architecture

- บอกว่ากลุ่มเราเลือก CNN backbone ตัวไหนมาบ้าง พร้อมเหตุผลสั้น ๆ
- แสดงประสิทธิภาพของโมเดล Pre-trained CNN (ที่ยังไม่ได้ตัดต่อเลเยอร์อะไรเข้าไปเลย และยังไม่มีการเทรนอะไรเพิ่มเลย) บนภาพตัวอย่างจาก A new image dataset ของเรารั่ว ๆ เช่น อาจแคปผลลัพธ์ภาพบางคลาสของเรามาให้ดูเป็นตัวอย่าง ว่า Pre-trained CNN ทายภาพของเรามั่วไปคลาสอื่นหมดเลย หรือใน Pre-trained CNN มันไม่มีคลาสที่ตรงเป๊ะกับของงานเราอยู่เลย => อันนี้ทำเพื่อให้เห็นที่มาว่า ทำไมเราถึงต้อง finetune มันเพิ่มเติมเท่านั้น นะคะ ไม่ต้องถึงกับไปทดลองหา accuracy/precision/recall/f1 มาคะ เพราะ pre-trained model มันยังไม่รู้จักคลาสเป้าหมายของเราอยู่แล้ว
- อธิบายว่าเราทำการตัดตอน original backbone ส่วนไหนออกไป หรือเก็บส่วนไหนไว้บ้าง
- ส่วนต่อเติมใหม่ที่เราเพิ่มเข้าไป (เช่น ส่วน classifier) ได้แก่ ส่วนไหนบ้าง, เพิ่มไปที่เลเยอร์, แต่ละเลเยอร์ต่อกันยังไง, และ รายละเอียดพารามิเตอร์ต่าง ๆ ของเลเยอร์ที่เพิ่มเข้าไปเป็นยังไง

4) Training method

- อธิบายวิธีการเทรน เช่น เรา freeze/unfreeze weights ของเลเยอร์ไหนไว้บ้าง, เลเยอร์ไหนบ้างที่จะถูก update weights ในระหว่างการเทรน, วิธีการอื่น ๆ ถ้าไม่ใช้การเทรนแบบมาตรฐาน end-to-end training, ฯลฯ

- พารามิเตอร์ที่ใช้ในการเทรน เช่น optimizer ที่เลือกใช้, สมการ loss ที่เลือกใช้, initial learning rate, LR scheduler, การตั้งค่า hyperparameter อื่น ๆ
- เทคนิคการทำ hyperparameter tuning ของกลุ่มเราว่าใช้เทคนิคอะไร ทั้งนี้ในกรณีงานกลุ่มแนะนำให้ใช้เครื่องมือ Optuna หรือ W&B ที่อาจารย์เคยสอนไป เพื่อช่วยทำ systematic hyperparameter running (พีเจอร์ W&B Sweep) และช่วยรวบรวมผลการทดลองของทุกคนในกลุ่มไว้ใน project เดียวกัน และคัดเลือกผลที่ดีที่สุดขึ้นมาได้ง่ายค่ะ

5) Evaluation metrics

- อธิบายว่างานนี้จะใช้ Metric อะไรในการประเมินบ้าง (ตัวชี้วัดยิ่งเยอะยิ่งดีสำหรับงาน DL เช่น ประเมินภาพรวมทุกคลาส, ประเมินแยกรายคลาส, confusion matrix, ฯลฯ)

6) Experimental results

- แสดงกราฟผลลัพธ์การเทรน เพื่อให้ดูได้ว่าเกิด overfit / underfit หรือเปล่า
- เปรียบเทียบผลลัพธ์ของโมเดลแต่ละตัว บน Evaluation metrics ทุกตัวที่พูดถึงในหัวข้อ 5
- ***ตัวเลขทุกตัวที่รายงานต้องเป็นค่า $\text{mean} \pm \text{SD}$ นะคะ*** โดยสำหรับโมเดล A ตัวที่ fix ค่า hyperparameter ทุกอย่างเรียบร้อยแล้ว ให้ทำการเทรนโมเดลนั้นซ้ำตั้งแต่ต้น อย่างน้อย 3 – 10 หน (แต่ละหนคือโมเดล A โครงสร้างเหมือนกันเป๊ะ แต่จะมี initial weights ต่างกัน) แล้วเอาโมเดล 3-10 ตัวที่ได้ (A1, A2, A3, ..., A10) นั้นมาวัดประสิทธิภาพบน Evaluation metrics ทุกตัว เพื่อแสดงผลโดยเฉลี่ยของโมเดล A ตัวนี้ในรูป $\text{mean} \pm \text{SD}$ ค่ะ
- เพื่อแสดงว่าความต่างของตัวเลขผลลัพธ์ที่เราได้สำหรับแต่ละ model architecture นั้นมัน statistically significant หรือไม่ มีพวกการคำนวณค่า p-value ประกอบด้วยยิ่งดีค่ะ (เช่น จากการทดลองพบว่า architecture B ชนะได้ค่า accuracy สูงสุด แต่ค่าที่ชนะนั้นมัน statistically significant หรือเปล่าถ้าเทียบกับ architecture A และ C?)




Image credit: https://papers.ssrn.com/sol3/papers.cfm?abstract_id=5395709

7) Discussion and conclusions

- วิเคราะห์ว่าผลการทดลองในหัวข้อ 6 สรุปได้ว่าตัวไหนดีที่สุด (แล้วดีที่สุດอย่างมีนัยสำคัญทางสถิติหรือเปล่า?) ตัวไหนแย่ที่สุด ตัวไหนดูแล้วเหมาะสมที่สุดที่จะนำไปใช้ในบริบทของงานเรา
- วิเคราะห์ค่าผลการทดลองว่ามีจุดไหนที่ค่าผิดปกติบ้างไหม ถ้ามีคิดว่าความผิดปกตินั้นน่าจะเกิดจากอะไร อนาคตควรแก้ไขยังไง
- GradCAM analysis รัน GradCAM เพื่อตรวจสอบว่าโมเดลของเราพยากรณ์โดยมองภาพถูกบริเวณที่ควรจะเป็นอยู่หรือไม่ ***อันนี้ขอว่าต้องมีนะสำหรับการบ้านนี้ โดยถ้า GradCAM อันที่อาจารย์สอนไม่ตอบโจทย์งานเรา จะใช้เทคนิคแนวเดียวกันตัวอื่นมาแทนก็ได้ค่ะ***
- Eyeball analysis แคปตัวอย่างผลลัพธ์ที่น่าสนใจเป็นภาพแยกมาให้คนดูเป็นตัวอย่างชัด ๆ เช่น ผลลัพธ์เปรียบเทียบระหว่าง โมเดล pre-trained (ที่ยังไม่ได้เทรนเพิ่ม) vs. โมเดล A ของเรา vs. โมเดล B ของเรา
- ทั้ง GradCAM analysis และ Eyeball analysis เป็นเทคนิคที่ใช้ดูได้ทั้งคลาสที่ผลลัพธ์ตัวเลขดีอยู่แล้วแต่เพื่อ recheck ย้ำว่าตัวเลขดีแต่ผลจริงมีอะไรผิดปกติหรือเปล่า หรือเพื่อ showcase ผลการทดลองอันที่เจ๋ง ๆ ของเรา แต่ที่เน้น ๆ คือเราควรดูคลาสที่ผลลัพธ์ตัวเลขมีอะไรไม่ปกติ หรือไม่เป็นไปตามความต้องการ หรือมีประเด็นชวนให้ตั้งคำถาม เพื่อทำ error analysis ว่าผลที่ไม่ดีหรือประเด็นต้องสงสัยนั้นมีพฤติกรรมยังไง และเราจะมามีวิธีแก้ไขยังไงในอนาคตค่ะ

- (Optional) Ablation Study: ในกรณีโมเดลที่ซับซ้อนซึ่งมีองค์ประกอบหลายส่วน การทำ ablation study จะช่วยยืนยันความสำคัญของแต่ละองค์ประกอบ และอาจทำให้พิจารณาตัดองค์ประกอบที่พบว่าไม่มีต่อประสิทธิภาพของโมเดลออกได้ค่ะ
6. สิ่งที่ต้องส่งในวันพรีเซนตการบ้าน (ตัวแทนกลุ่ม 1 คนส่งในโพสต์ที่กำหนด โดยระบุชื่อกลุ่ม และ tag สมาชิกทุกคนในกลุ่มนะคะ)
- 1) ไฟล์ PDF รายชื่อสมาชิก รูปภาพสมาชิก และรายละเอียดหน้าที่ความรับผิดชอบของแต่ละคน ตั้งชื่อไฟล์ว่า HW_ชื่อกลุ่ม_member.pdf
 - 2) ไฟล์ PDF ของสิ่งที่นำเสนอ (โดยอาจเป็น presentation slides หรือ unofficial report หรือ github ก็ได้ แต่ต้องเปิดให้เพื่อนทุกคนในคลาสและอาจารย์สามารถเข้าไปกดอ่านได้) ตั้งชื่อไฟล์ว่า HW_ชื่อกลุ่ม_presentation.pdf
 - 3) (Optional) ไฟล์คลิปวิดีโอของการนำเสนอผลงาน (ถ้ามี) ตั้งชื่อไฟล์ว่า HW_ชื่อกลุ่ม_presentation.mp4

***** THE END *****